



Онлайн-занятие по подготовке участников к отборочному этапу Всероссийской олимпиады по искусственному интеллекту 2023

19 сентября 13:00



Программа онлайн-занятия

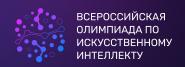


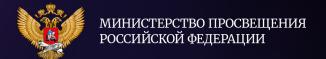
1. Структура Всероссийской олимпиады по ИИ 2023

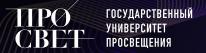
- Регистрация на олимпиаду
- Структура олимпиады
- Отборочный этап

2. Подготовка к решению заданий отборочного этапа

- Задания по математике
- Задания по машинному обучению
- Задания по алгоритмам





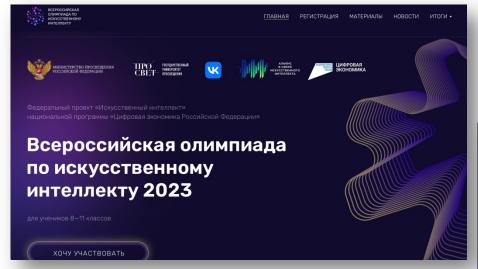




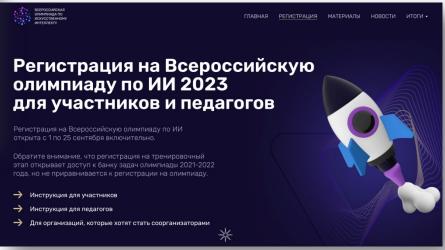


Официальный сайт олимпиады

https://ai.edu.gov.ru







Как зарегистрироваться

Для участия в Олимпиаде необходимо зарегистрироваться на двух платформах: «Сферум» и «All Cups». Подробный алгоритм опубликован на сайте Олимпиады: https://ai.edu.gov.ru/registration





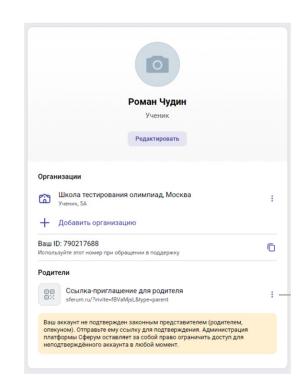
Сферум - это защищенная платформа для организации учебного процесса, дающая возможность всем ее участникам взаимодействовать между собой.



All Cups - онлайн-платформа для проведения олимпиад и чемпионатов по направлениям ML, Al, Спортивное программирование, Highload.

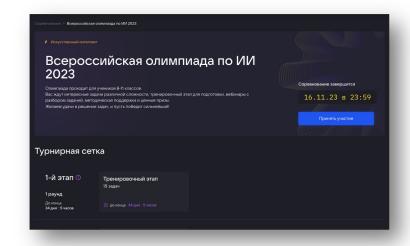
Какие шаги нужно пройти участнику на «Сферум»

- Проверь, есть ли у твоей учетной записи принадлежность к образовательной организации со статусом **«Ученик».**
- Проверь, закреплен ли **Родитель** за твоим аккаунтом (если тебе еще не исполнилось 18 лет).
- Попроси **Родителя** дать согласие на обработку твоих персональных данных (если тебе еще не исполнилось 18 лет).

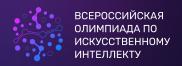


Какие шаги нужно пройти участнику на «All Cups»

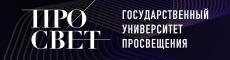
- Зарегистрируйся или авторизуйся под уже существующим аккаунтом «All Cups».
- На странице Олимпиады нажми на «Принять участие», выбери направление, подтверди согласие с Положением и Регламентом, привяжи свой аккаунт «Сферум».
- Дождись проверки твоего аккаунта на «Сферум». Исправить замечания при необходимости.



Получи сообщение об успешной регистрации!









Структура Олимпиады

Структура олимпиады



Олимпиада проходит в три этапа:

1. Отборочный этап

- онлайн
- 5 дней
- 26 сент. 10:00 30 сент. 23:59

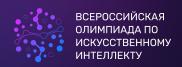
2. Основной этап

- онлайн
- 4 дня
- 11 окт. 10:00 14 окт. 23:59

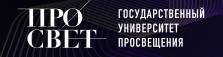
3. Заключительный этап

- 0440
- 2 дня по 6 часов
- 15-16 ноября













Отборочный этап состоит из 6 заданий, которые можно решать в произвольном порядке. Итоговый рейтинг строится по сумме баллов за каждое задание:

- 2 задания по математике количество набранных баллов определяется количеством пройденных тестов.
- 2 задания по алгоритмам количество набранных баллов определяется количеством пройденных тестов.
- 2 задания по анализу данных и ML критерием присвоения баллов является совпадение ответа участника с эталонным ответом (задача №1) и абсолютная процентная ошибка предсказания обученной модели (задача №2).



Задания по математике

Два задания на проверку знаний по темам, непосредственно связанным с анализом данных:

- Комбинаторика,
- Основы теории вероятностей,
- Основы теории графов,
- Базовые математические знания.

Задания по алгоритмам

Два задания по алгоритмам, требующие умения писать код. В задачах есть математическая подоплека, то есть математическую формулировку необходимо перевести в код. Задачи проходят через набор автоматических тестов.



Задание 1 (анализ данных)

На основе некоторого набора данных нужно провести их разведочный анализ, то есть ответить на вопросы по данным:

- изучить пропущенные значения и наличие выбросов,
- изучить столбцы и их особенности,
- исследовать взаимодействие столбцов.

Задание 2 (машинное обучение)

Задача классификации или регрессии или другая задача одного из распространенных типов.

Требуются:

- методы обработки данных,
- знания о том, как строить и валидировать ML-модели,
- знания о том, как настраивать гиперпараметры моделей.



Языки программирования:

- Для задач по алгоритмам рекомендуются языки C++ и Python,
- Для задач по машинному обучению ожидается знание Python.

Рекомендуемые требования к рабочим местам для комфортного решения заданий отборочного этапа:

- Процессор с тактовой частотой ядра не менее 2,1ГГц и количеством ядер не менее 6.
- Оперативная память не менее 16 гб,
- Жесткий диск SSD на менее 128 гб,
- Видеокарта внешняя Nvidia с объемом видеопамяти от 8 гб,
- OC Windows,
- Монитор не менее FHD (1920*1080), 60Hz,
- Клавиатура, мышь.

^{*}Оборудование участника может отличаться в меньшую сторону от заявленного в требованиях.

Загрузка решений

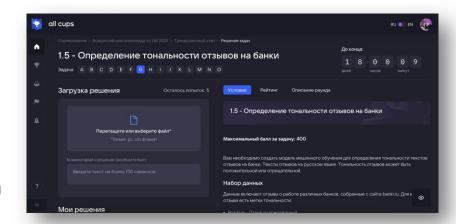


1. Для загрузки решений переходите в рабочее пространство.

Загрузка доступна только с компьютера — на телефоне и планшете вы можете просто ознакомиться с результатами.

2. Время обсчёта решений.

В среднем задачи с кодом обсчитываются за 1–2 минуты. Задачи по ML — до 10 минут. В случае большого количества решений будет создана очередь и время может быть увеличено.



Штраф и дисквалификация



Важно соблюдать правила, описанные в Регламенте олимпиады.

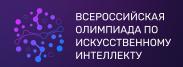
Коротко о том, за что мы можем дисквалифицировать:

- 1. Использование нескольких аккаунтов и авторизация под аккаунтом другого участника.
- 2. Попытка намеренно взломать систему проверки решений.
- 3. Публикация решения заданий или обсуждение методов решения заданий до окончания отборочного этапа олимпиады.
- 4. Использование чужого решения, даже если чужое решение было изменено или доработано.
- 5. Прямая передача своего решения другим участникам.

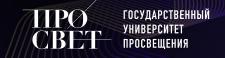
Как проходит дисквалификация



- После завершения этапа олимпиады мы передаем результаты для определения проходного балла членами жюри. Вместе с результатами передаются выявленные инциденты по нарушению правил.
- Члены жюри оценивают степень нарушения и выносят итоговый вердикт.
- В случае признания нарушения результаты участника обнуляются, и он не отражается в итоговом рейтинге. На email участника отправляется письмо с детальным разбором нарушения.
- В течение 24 часов участник имеет право обжаловать решение, аргументировав отсутствие нарушения.
- Аргументы участника дополнительно рассматриваются членами жюри, и он может быть восстановлен в рейтинге.









Подготовка к решению заданий по математике



<u>Разделы математики, которые могут встретиться в заданиях отборочного этапа</u> (всего 2 задания):

- Математический анализ,
- Линейная алгебра,
- Дискретная математика (комбинаторика и основы теории графов),
- Основы теории вероятностей.

В задачах олимпиады первые две темы проверяют только базовые школьные навыки и содержатся в формулировках заданий по математике и алгоритмам. Дополнительно готовиться к этим темам не нужно, но желательно потренироваться решать соответствующие задачи из школьной программы. Необходимо знать, что такое знак суммирования, факториал и так далее.



Дискретная математика (комбинаторика и основы теории графов)

Для подготовки к задачам по дискретной математике рекомендуется изучение или повторение следующих тем:

- Основные понятия и формулы комбинаторики (перестановки, размещения, сочетания),
- Решение задач по комбинаторике повышенной сложности,
- Рекуррентные соотношения в комбинаторике,
- Написание программ, реализующих те или иные формулы в комбинаторике,
- Основы теории графов (понятие связности графа, умение решать несложные задачи школьного уровня по данной теме).



Дискретная математика (комбинаторика и основы теории графов)

Из конкретных тем, на которые стоит обратить внимание:

- Бином Ньютона,
- Числа Каталана,
- Рекуррентные соотношения в комбинаторике.

Потренируйтесь решать комбинаторные задачи путем написания кода! Часто формулы комбинаторики можно представить в виде рекуррентного соотношения, которое удобно представить в виде кода программы и быстро посчитать на компьютере.



1. Дискретная математика (пример):

Укротитель хищных зверей хочет вывести на арену цирка 5 львов и 4 тигров, при этом нельзя, чтобы два тигра шли друг за другом. Сколькими способами он может расположить зверей?





1. Дискретная математика (пример)

Решение:

- Поставим сначала всех львов так, чтобы между каждыми двумя львами был промежуток 5! = 120 способов
- Число промежутков равно 4. Если присоединить к ним еще два места впереди всех львов и позади них, то получим 6 мест, на которые можно поставить по тигру. Порядок тигров важен, поэтому число способов их расстановки $A_6^4=360$
- Итого для каждой расстановки львов имеем 360 расстановок тигров. Значит, ответ $120 \cdot 360 = 43200$



2. Рекуррентные соотношения (пример):

Существует известная рекуррентная формула, связывающая между собой биномиальные коэффициенты:

$$C_n^k = C_{n-1}^k + C_{n-1}^{k-1}$$

- Благодаря этой формуле мы можем, используя программу, посчитать очень большие значения \mathcal{C}_n^k , которые напрямую посчитать не можем.
- Лучше использовать динамическое программирование, нежели рекурсивный подход.

Пример:

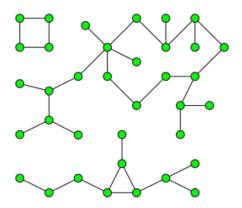
https://colab.research.google.com/drive/15TW8t_uvtavfPuH3KbGfWno28h5BNp9o?usp=sharing





3. Основы теории графов (пример):

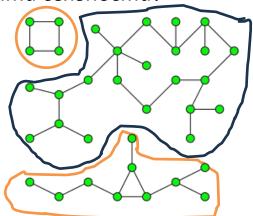
Сколько компонент связности в данном графе? Сколько вершин содержит самая большая компонента связности?





3. Основы теории графов (пример):

Сколько компонент связности в данном графе? Сколько вершин содержит самая большая компонента связности?



Ответ: 3 компоненты связности; 22 вершины.



Основы теории вероятностей

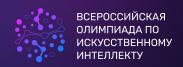
Для подготовки к задачам по данной теме рекомендуется изучить или повторить следующие темы:

- Основные понятия и формулы теории вероятностей (определение вероятности, сумма и перемножение вероятностей, понятие независимых событий);
- Формула полной вероятности, формула Байеса;
- Решение задач по теории вероятностей стандартной и повышенной сложности.

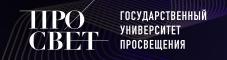


Литература для подготовки:

- https://problems.ru
- Виленкин Н.Я., Виленкин А.Н., Виленкин П.А.: Комбинаторика
- http://mathprofi.ru/teorija verojatnostei.html
- https://foxford.ru/wiki/matematika/grafy
- Карпов Д.В. Теория графов
- Горбачев Н.В. Сборник олимпиадных задач по математике









Подготовка к решению заданий по машинному обучению



Задание 1: разведочный анализ данных (постановка задачи)

В этом задании необходимо ответить на вопросы по табличным данным разной сложности:

- Найти число пропусков в колонках,
- Число специфических значений,
- Число строк, удовлетворяющих некоторым условиям,
- Ответить на смысловые вопросы относительно данных.



Задание 1: разведочный анализ данных (что изучить)

Что пригодится:

- Простые методы работы со строковыми данными (вычленение определенных паттернов, слов из строк, подсчет количества различных слов и тд.);
- Простые методы работы с датами (извлечение года/месяца/дня из даты);
- Работа с числовыми данными: вычисление различных числовых характеристик столбцов.



Задание 1: разведочный анализ данных (какие библиотеки нужны)

Рекомендуется решать задание на языке программирования Python.

Пригодятся следующие библиотеки:

- Pandas для работы с таблицами,
- Numpy для быстрых численных операций,
- *Matplotlib* для построения визуализаций.





Задание 2: машинное обучение (задача классического типа)

В этом задании потребуется решить задачу одного из классических типов (классификация, регрессия) на табличных данных.

- *Классификация* задача, где требуется спрогнозировать для каждого объекта ответ, принадлежащий конечному множеству, например:
 - Вернет клиент кредит или не вернет,
 - Болен пациент или здоров,
 - Какой балл от 1 до 5 получит школьник за экзамен и тд.
- *Регрессия* задача, где для каждого объекта требуется спрогнозировать величину, принимающую значения из некоторого бесконечного множества:
 - Прогноз прибыли компании,
 - Прогноз курса валют и тд.



Задание 2: машинное обучение (что изучить)

Очень пригодятся различные методы работы с табличными данными:

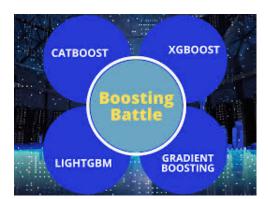
- Однофакторный анализ (заполнение пропущенных значений, поиск и обработка выбросов);
- Оценка взаимосвязи факторов между собой, а также влияния каждого фактора на целевую переменную (корреляции и их аналоги;
- Методы отбора признаков и снижения размерности;
- Методы обработки категориальных признаков (one-hot кодирование, кодирование счетчиками и так далее).



Задание 2: машинное обучение (что изучить)

Для построения прогнозов пригодятся модели машинного обучения:

- Линейная регрессия (а также варианты с регуляризацией);
- Линейные классификаторы (логистическая регрессия, метод опорных векторов и его модификации);
- Решающие деревья и леса;
- Бустинг (полезно изучить современные имплементации бустинга, такие как XGBoost, CatBoost, LightGBM).





Пример: датасет Титаник

Задачи:

- Провести разведочный анализ данных: выявить факторы, влияющие на выживаемость;
- Потренироваться строить модели.

Ноутбук с примером анализа данных.

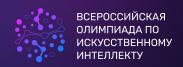




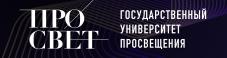


Материалы для подготовки:

- https://academy.yandex.ru/handbook/ml
- https://www.kaggle.com/learn
- https://scikit-learn.org/stable/tutorial/index.html
- ссылки в ноутбуке









Подготовка к решению заданий по алгоритмам

Как выглядит решение задачи



- Для «алгоритмических» заданий решение код программы.
- Программа должна прочитать данные из стандартного потока ввода-вывода (консоли) и записать ответ туда же.
- Код должен быть в одном файле.
- Доступны только стандартные библиотеки. Запрещён доступ в интернет и к файловой системе.
- Решение тестируется на нескольких тестах.
- Ограничение по времени и памяти распространяется на каждый тест.

Процесс тестирования



- 1. Загрузка решения.
- 2. Компиляция решения (для соответствующих языков).
- 3. На каждом тесте:
 - а) запуск решения;
 - b) проверка ответа;
 - с) выставление баллов.

Типичные вердикты



- CE (Compilation error) ошибка компиляции.
- **TL** (Time limit exceeded) превышено время выполнения программы.
 - ML (Memory limit exceeded) превышено ограничение по памяти.
- **CR** (Non-zero code) программа не вернула 0.
- **RE** (Runtime error) программа по какой-то причине не выдала ответ.
- **PE** (Presentation error) выведено неверное число строк.
- WA (Wrong answer) неправильный ответ.
- OK (Correct answer) правильный ответ.

Редкие вердикты



- IL (Idleness limit exceeded) превышено время бездействия.
- **SV** (Security violation) программа выполнила небезопасные операции.
- **SE** (Server Error) ошибка в проверяющей системе, сообщите организатору.

Типичные ошибки



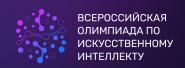
- При отправке неверно выбран язык программирования или задача.
- Версия языка не совпадает с версией в тестирующей системе.
- Неэффективное решение.
- Лишняя информация в выводе программы.
- Не учтён какой-нибудь крайний случай.
- Произошло переполнение. Выбран неверный тип чисел.
- Медленный ввод или вывод.
- В Python деление на 0.0 вызывает ошибку (даже если это float!).
- Выводится слишком мало знаков после десятичного разделителя. Но небольшое отклонение не является ошибкой.
- В качестве десятичного разделителя используется не точка. Но научная нотация (например 1е-9) не являете ошибкой.

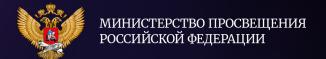
Задания по алгоритмам

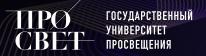


Необходимые знания для отборочного этапа:

- Базовые конструкции в языках (циклы, условия и т.д.).
- Работа с различными типами (строки, вещественные числа и т.д.).
- Базовые структуры данных (массив, список, множество, словарь).
- Базовые алгоритмы (бинарный поиск, два указателя, сумма на отрезке, жадные алгоритмы, динамическое программирование и т.д.).
- Базовая математика (возведение в степень, раскрытие скобок и т.д.).









Если у вас появятся вопросы по Олимпиаде, вы всегда можете написать нам на почту <u>ai@guppros.ru</u>или в официальный чат участников ВКонтакте:

